

Implementação e Avaliação de Algoritmos de Machine Learning para Previsão de Ataques Cibernéticos

Emili Vieira Tabuti* e Daniel Couto Gatti**

*Ciência da Computação, Pontifícia Universidade Católica de São Paulo

**Faculdade de Ciências Exatas e Tecnologia, Pontifícia Universidade Católica de São Paulo

E-mails: **TODO: informar e-mail institucional da estudante; TODO: informar e-mail institucional do orientador**

Resumo: Esta pesquisa implementou e avaliou algoritmos de aprendizado de máquina para apoiar alertas de segurança de redes. Random Forest, Decision Tree e LSTM foram comparados no UNSW-NB15 por três folds cronológicos expansivos e um teste futuro fechado. Pré-processamento e seleção de atributos foram ajustados somente no treino de cada fold, e as janelas de dez registros não atravessaram partições, sessões ou arquivos. O protocolo selecionou 10 atributos para Decision Tree, 20 para LSTM e 30 para Random Forest antes da única abertura do teste. Em 306.701 janelas futuras, o Random Forest alcançou F1 de 0,9261, PR-AUC de 0,9856 e revocação de 0,9525, permanecendo próximo do F1 médio de 0,9236 no desenvolvimento. O modelo vencedor foi integrado a uma API que recebe dados brutos e executa internamente pré-processamento, seleção e inferência. Uma análise prospectiva adicional definiu horizontes de 5 a 60 segundos, mas encontrou somente cinco eventos adequados após excluir ataques ativos ou recentes, número insuficiente para avaliar antecipação. O estudo entrega um protótipo funcional de detecção, uma avaliação de generalização temporal e os requisitos para continuar a pesquisa sobre previsão antecipada.

Palavras-chave: Aprendizado de Máquina. Segurança Cibernética. Detecção de Intrusões. Random Forest. LSTM.

Classificação das áreas de conhecimento: 1.03.00.00-7 — Ciência da Computação; 1.03.06.00-5 — Inteligência Artificial.

Introdução

Redes acadêmicas reúnem serviços, dispositivos e perfis de uso heterogêneos, condição que amplia a superfície de ataque e dificulta a manutenção de regras fixas. Sistemas de detecção de intrusões analisam eventos e tráfego para reconhecer comportamentos maliciosos, mas abordagens baseadas apenas em assinaturas dependem da atualização contínua de padrões conhecidos.

O aprendizado de máquina pode complementar esses mecanismos ao estimar relações entre atributos de tráfego e rótulos de segurança. A literatura apresenta árvores de decisão, métodos de ensemble e redes profundas para essa finalidade [1–4]. Contudo, diferenças entre conjuntos, atributos e protocolos experimentais dificultam comparações diretas [3]. Duplicações, sobreposições e vazamento de informação entre partições também podem elevar artificialmente as métricas [5].

Este trabalho integra uma pesquisa sobre alertas para redes acadêmicas e concentra-se no módulo de aprendizado de máquina. O estudo utilizou o UNSW-NB15, conjunto público que preserva timestamps e favorece a reprodução.

A pesquisa avaliou a possibilidade de construir rótulos futuros com os dados temporais disponíveis. Como o protocolo estrito encontrou poucos eventos adequados para essa finalidade, a implementação funcional prosseguiu com a detecção do estado atual do tráfego a partir dos registros recentes.

Objetivos

O objetivo geral foi implementar e avaliar algoritmos de aprendizado de máquina para apoiar um sistema de alerta de segurança. Os objetivos específicos abrangeram revisão bibliográfica, seleção e treinamento dos modelos, padronização das métricas, comparação dos resultados e serialização dos artefatos.

O trabalho também avaliou se os dados disponíveis permitiam formular uma tarefa prospectiva e buscou disponibilizar o modelo selecionado por uma API integrada ao painel de visualização.

Metodologia

O estudo adotou abordagem quantitativa e experimental, sem coleta com participantes humanos. O UNSW-NB15 contém 1.584.259 registros, 43 campos brutos elegíveis e 204 atributos após o pré-processamento.

Para avaliar a viabilidade da previsão, os fluxos do UNSW-NB15 foram ordenados por arquivo e tempo. Ataques ativos foram definidos pelo intervalo inclusivo entre *Stime* e *Ltime*, e os rótulos indicaram o início de um ataque nos 5, 15, 30 ou 60 segundos seguintes.

A etapa prospectiva excluiu instantes com ataque em andamento e calculou sessenta atributos usando somente fluxos concluídos nos 30, 60 ou 120 segundos anteriores. Um filtro adicional removeu históricos com ataques concluídos nos últimos 120 segundos, e uma purga de 180 segundos separou as partições temporais.

Como essa análise identificou poucos eventos adequados para previsão, o treinamento dos modelos prosseguiu com foco na detecção de ataques presentes nos dados.

O pré-processamento removeu duplicações exatas, tratou valores ausentes e aplicou transformação logarítmica em colunas muito assimétricas. O *RobustScaler* realizou o escalonamento por mediana e intervalo interquartil, enquanto as variáveis categóricas do UNSW-NB15 receberam codificação one-hot. Categorias e estatísticas foram aprendidas apenas no treino de cada fold.

Cada exemplo reuniu dez registros consecutivos. A LSTM recebeu a representação sequencial, enquanto Random Forest e Decision Tree utilizaram as janelas achatadas. O alvo correspondeu ao décimo registro, preservando nove observações anteriores como contexto.

O Random Forest utilizou cem estimadores, profundidade máxima igual a vinte e execução em dois processos paralelos. A Decision Tree também adotou profundidade máxima de vinte. A LSTM empregou 64 unidades recorrentes, uma camada densa de 32 unidades e saída sigmoide.

O UNSW-NB15 foi ordenado por tempo e dividido em três sessões naturais. Depois da purga, treino, validação e teste reuniram 1.023.187, 254.326 e 306.710 registros. O desenvolvimento usou três folds cronológicos expansivos, sem embaralhamento e com embargo suficiente para garantir que os fluxos de treino terminassem antes do início da validação.

Cada algoritmo foi avaliado com todos os 204 atributos e com os 10, 20 e 30 primeiros de um ranking aprendido somente no treino, totalizando 36 execuções. F1 foi a métrica primária, complementada por PR-AUC, AUC-ROC, precisão, revocação e taxa de falsos positivos. O protocolo congelou Decision Tree `top_10`, LSTM `top_20` e Random Forest `top_30` antes de abrir o teste.

Os modelos finais foram ajustados em treino+validação e avaliados juntos uma única vez em 306.701 janelas do teste futuro. O Random Forest vencedor foi serializado com pré-processador, seleção e esquema bruto e disponibilizado por uma API FastAPI. Na versão auditada, a suíte automatizada aprovou 175 testes.

Resultados e discussão

No desenvolvimento temporal, o melhor F1 médio foi $0,8923 \pm 0,0235$ para Decision Tree com 10 atributos, $0,8812 \pm 0,0156$ para LSTM com 20 e $0,9236 \pm 0,0211$ para Random Forest com 30. As três seleções superaram as configurações com todos os atributos. No Random Forest, a redução de 204 para 30 atributos correspondeu a 85,3% da entrada por registro.

No teste futuro, o Random Forest alcançou F1 de 0,9261, PR-AUC de 0,9856, AUC-ROC de 0,9987, precisão de 0,9010, revocação de 0,9525 e FPR de 0,0094. A Decision Tree obteve F1 de 0,8898, e a LSTM, 0,8846. O F1 do vencedor ficou apenas 0,0025 acima da média de desenvolvimento, sem ajuste posterior ao teste.

O Random Forest apresentou o maior F1 em todas as categorias do teste, mas as classes raras permaneceram difíceis. O F1 foi 0,0301 para Worms, 0,2187 para Shellcode, 0,3054 para Analysis e 0,3187 para Backdoor. Esses valores mostram que PR-AUC e métricas por categoria são necessárias mesmo quando a separação global medida por AUC-ROC é alta.

Essas diferenças demonstram que métricas agregadas não descrevem toda a capacidade do sistema. Uma avaliação operacional deve considerar cada categoria e o custo dos erros. O protótipo serializou Random Forest e LSTM, e a API adotou o Random Forest como modelo padrão, demonstrando a integração técnica com o painel. Entretanto, não houve validação em tráfego de uma rede acadêmica real.

O teste representa uma sessão posterior, não compartilha registros com o desenvolvimento e não participa do ajuste das transformações. Por isso, o resultado constitui evidência de generalização temporal [5].

O alvo do pipeline de comparação descreve o estado no final da janela corrente. Dessa forma, o modelo identifica ataques presentes com apoio dos registros anteriores, enquanto a previsão antecipada requer horizonte explícito, atributos estritamente históricos e divisão temporal [7].

A avaliação prospectiva identificou 277 períodos de ataque em 66.484 instantes. Antes do filtro estrito, existiam entre 337 e 466 rótulos positivos, mas 85% a 97% deles continham ataques no

histórico. Esses casos representavam principalmente persistência ou recorrência do mesmo período de ataque.

Após a exclusão de ataques recentes, restaram 37.311 instantes e somente cinco eventos estritos. O treino recebeu três eventos, e validação e teste receberam um evento cada. Nos horizontes de 30 e 60 segundos, as duas partições futuras não possuíam exemplos negativos.

Essa distribuição não ofereceu elementos suficientes para comparar modelos prospectivos. O UNSW-NB15 permanece adequado para detecção, classificação, recorrência e auditorias metodológicas, enquanto a previsão estrita depende de mais eventos de ataque separados e períodos benignos anteriores.

Conclusões

O trabalho implementou três modelos e um fluxo auditável de avaliação temporal, além de entregar artefato serializado, API e integração com painel. O Random Forest `top_30` apresentou o melhor equilíbrio no período futuro e foi adotado no serviço. A avaliação por categoria evidenciou fragilidade nas classes raras e confirmou que métricas globais devem ser acompanhadas por análises específicas.

A pesquisa avaliou as condições para previsão antecipada e verificou que os dados disponíveis não contêm eventos suficientes para essa avaliação. Com base nesse resultado, o protótipo foi desenvolvido para identificar o estado atual do tráfego, tarefa compatível com a estrutura das bases utilizadas.

A continuidade exige uma coleta controlada que identifique separadamente cada evento de ataque e registre períodos benignos, possíveis precursores e fases de recuperação. Eventos completos e distintos devem compor treino, validação e teste, acompanhados de execuções inteiramente benignas.

Uma auditoria identificou diferenças entre versões de dependências registradas no protocolo e usadas na execução final. As decisões permaneceram congeladas e o teste não foi repetido, mas o desvio deve acompanhar a interpretação e a reprodução do experimento. Em estudos futuros, o ambiente executável também deverá ser congelado antes da abertura do teste.

O protocolo prospectivo deverá ser definido antes do treinamento, e todas as transformações deverão ser ajustadas somente no treino. A avaliação final deve preservar um teste fechado e incluir PR-AUC, revocação por evento, antecedência do primeiro alerta e falsos alertas por hora.

Agência de Fomento

Programa Institucional de Bolsas de Iniciação Científica do Conselho Nacional de Desenvolvimento Científico e Tecnológico — PIBIC-CNPq.

Referências

- [1] BERTOLI, G. C. et al. An end-to-end framework for machine learning-based network intrusion detection system. *IEEE Access*, v. 9, p. 106790–106805, 2021. DOI: 10.1109/ACCESS.2021.3101188.
- [2] YIN, C. et al. A deep learning approach for intrusion detection using recurrent neural networks. *IEEE Access*, v. 5, p. 21954–21961, 2017. DOI: 10.1109/ACCESS.2017.2762418.
- [3] LE JEUNE, L.; GOEDEMÉ, T.; MENTENS, N. Machine learning for misuse-based network intrusion detection: overview, unified evaluation and feature choice comparison framework. *IEEE Access*, v. 9, p. 63995–64015, 2021. DOI: 10.1109/ACCESS.2021.3075066.
- [4] BERMAN, D. S. et al. A survey of deep learning methods for cyber security. *Information*, v. 10, n. 4, art. 122, 2019. DOI: 10.3390/info10040122.
- [5] TRAN, N. et al. Data curation and quality evaluation for machine learning-based cyber intrusion detection. *IEEE Access*, v. 10, p. 121900–121923, 2022. DOI: 10.1109/ACCESS.2022.3211313.
- [6] SHAO, Lisong et al. Design and implementation of a machine learning-based network intrusion detection system. In: ASIA PACIFIC CONFERENCE ON COMPUTING TECHNOLOGIES, COMMUNICATIONS AND NETWORKING, 2024, Chengdu. *Proceedings [...]*. New York: ACM, 2024. p. 137–142. DOI: 10.1145/3685767.3685790.
- [7] ANKALAKI, S. et al. Cyber attack prediction: from traditional machine learning to generative artificial intelligence. *IEEE Access*, v. 13, p. 44662–44706, 2025. DOI: 10.1109/ACCESS.2025.3547433.